Øving 3

Jeg valgte deloppgave 3, som handler om å forbedre quicksort-algoritmen ved å hoppe over deltabeller der de avgrensende pivot-elementene er like.

I programmet har jeg programmert to algoritmer. Den ene algoritmen er en standard quicksort-algoritme. Den andre er en kopi av den første, men med den forbedringen som er beskrevet i oppgaven.

Merk! *Resultatene i denne rapporten har blitt produsert av å kompilere programmet på Windows med VS2022-kompilatoren, med C-standard 14.*

Hva er det programmet printer ut?

Programmet printer først ut en rekke tidsmålinger for begge algoritmene. Dette er testene i riktig rekkefølge:

- Sortering av tilfeldige verdier
- Sortering av tilfeldige verdier med mange duplikater
- Sortering av ferdigsortert data
- Sortering av ferdigsortert data med mange duplikater
- Kompleksitets-måling av den gitte algoritmen. Altså at algoritmen påkalles flere ganger med en n-verdi som øker med en faktor på 10.

Deretter printer programmet ut en lineær målserie mellom 3,000,000 og 10,000,000 for hver av algoritmene. Dette brukes til å estimere en graf for hver algoritmes kompleksitet. Input-dataene som sorteres er tabeller med tilfeldige verdier.

Output for godkjenningskravene til deloppgave 3

Dette er et resultat av målingene fra når jeg har kjørt programmet selv.

a) 0.542717s – vanlig quicksort på mange duplikater.
b) 0.354419s – forbedret quicksort på mange duplikater.
c) 0.624043s – forbedret quicksort på tilfeldige tall.
    a. 0.728514s – vanlig quicksort på tilfeldige tall.

Oppgaveteksten hinter til at forandringen vil gjøre algoritmen tregere for data som kjører Som vi kan se, lider ikke den forbedrede algoritmen av høyere kjøretid på vanlige sorteringer av tilfeldige tall. Det er fordi jeg fant ut at det er mer effektivt å videreføre tabell-kantene til hver rekursjon, enn å lete etter min/max-verdier for hver eneste deltabell. Den negative siden ved dette er at forbedringen aldri vil kjøre for deltabeller som ligger på kantene til den originale tabellen. Men utfra måleresultatene, ser vi at dette ikke er et stort problem.

Hvordan testes algoritmene?

Algoritmene testes hver eneste gang de blir påkalt, uansett situasjon. Dette gjøres ved at programmet alltid påkaller en template funksjon 'test_sort_function'. Den tar en sorteringsalgoritme

som input, gjennomfører checksum-validering (med std::accumulate før og etter sortering), og sjekker at tabellen faktisk er sortert (via std::is_sorted etter sortering).

Bruken av STL-funksjoner er for å unngå feil i valideringsmetode. Det fjerner en kritisk fallgruve der det er feil i valideringsmetodene jeg lager selv.

Algoritmene

Dette er den vanlige quicksort algoritmen jeg har laget:

```
80  template <class T>
81  void custom_quick_sort(T* data, size_t count) {
82      if (count < 1)
83          return;
84
85      T* end = data + count;
86      T* last = end - 1;
87
88      if (count > 2) {
89          T* middle = splitt(data, count);
90          custom_quick_sort(data, middle - data);
91          middle++;
92          custom_quick_sort(middle, end - middle);
93      } else {
94          if (*data > *last)
95              bytt(data, last);
96      }
97  }
```

Dette er den forbedrede versjonen av algoritmen. Jeg har markert de viktigste forskjellene.

Måten jeg har implementert forbedringen, er ved å lage en inner-funksjon som den offentlige funksjonen påkaller. Den offentlige funksjonen fyller inn 'bound_begin' og 'bound_end', og innerfunksjonen viderefører disse verdiene. På denne måten har alltid innerfunksjonen direkte tilgang på original-tabellens grenser, og kan sjekke om den nåværende del-tabellen grenser

```
101  template <class T>
102  void custom_quick_sort_improved_inner(T* data, size_t count, const T* bound_begin, const T* bound_end) {
103      if (count < 1)
104          return;
105
106      T* end = data + count;
107      T* last = end - 1;
108
109
110      if (data != bound_begin && end != bound_end && count > 1) {
111          // If the pivots bounding this sub-array are equal...
112          if (*(data - 1) == *(last + 1))
113              return; // ... we can skip processing this sub-array
114      }
115
116      if (count > 2) {
117          T* middle = splitt(data, count);
118          custom_quick_sort_improved_inner(data, middle - data, bound_begin, bound_end);
119          middle++;
120          custom_quick_sort_improved_inner(middle, end - middle, bound_begin, bound_end);
121      } else {
122          if (*data > *last)
123              bytt(data, last);
124      }
125  }
126
```

Resultat

Her er en linær måleserie for begge algoritmene. Begge algoritmene har sortert

N-verdi	Quicksort (s)	Quicksort med forbedring (s)
3000000	0.210071	0.189333
3250000	0.226494	0.203236
3500000	0.245356	0.220587
3750000	0.260281	0.232495
4000000	0.281686	0.245342
4250000	0.295004	0.260181
4500000	0.316466	0.280357
4750000	0.33577	0.298179
5000000	0.349851	0.310329
5250000	0.366912	0.328523
5500000	0.381151	0.333745
5750000	0.408172	0.357405
6000000	0.422121	0.368845
6250000	0.435679	0.379885
6500000	0.462744	0.402744
6750000	0.480546000000001	0.420034
7000000	0.499253000000001	0.433949
7250000	0.521472000000001	0.45196
7500000	0.530699000000001	0.456754
7750000	0.550377000000001	0.475657000000001
8000000	0.571091000000001	0.493472000000001
8250000	0.585284000000001	0.505308000000001
8500000	0.602384000000001	0.520224000000001
8750000	0.627852000000001	0.540457000000001
9000000	0.641316000000001	0.558360000000001
9250000	0.667941000000001	0.582934000000001
9500000	0.678741000000001	0.585340000000001
9750000	0.694589000000001	0.594657000000001
10000000	0.710804000000001	0.609456000000001
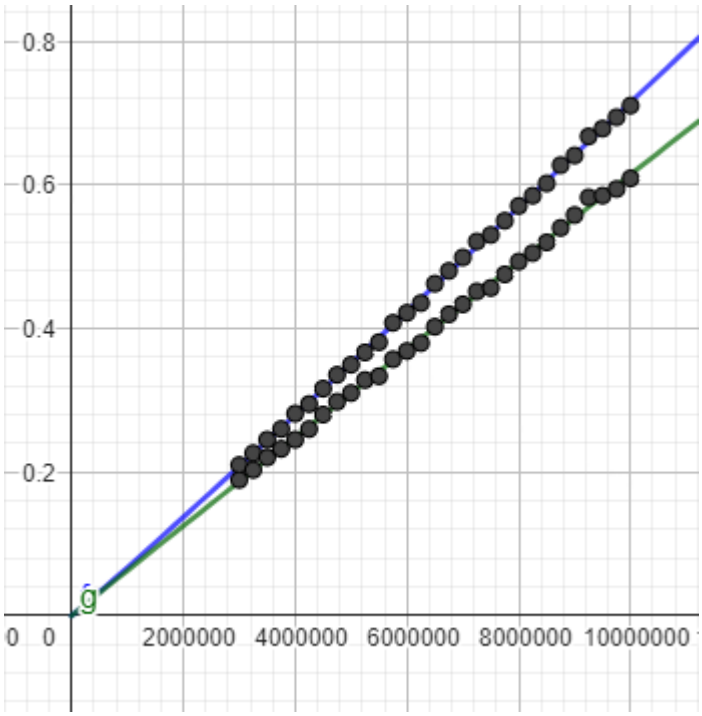
Når vi plotter disse verdiene i Geogebra, og bruker funksjonen «fit» med $x * \log(x)$ som grunn-funksjon, får vi disse to grafene. Grafen med lavest stigning tilhører den forbedrede quicksort-algoritmen. Her kan vi se tydeligere at den forbedrede algoritmen har en bedre utvikling enn den vanlige quicksort-algoritmen.